

Benchmarking solvers for the traveling salesman problem in last-mile delivery

Rafael Maziero Araujo

Prof. Dr. Marlon Fernandes de Souza

Escola Superior de Agricultura "Luiz de Queiroz" | Universidade de São Paulo (USP)

rafamazaraujo@usp.br

Objetivos

O objetivo principal deste trabalho é comparar cinco algoritmos aplicados ao "Problema do Caixeiro-Viajante" (PCV), avaliando qualidade de solução e tempo de execução. São comparados neste trabalho três metaheurísticas, um algoritmo genético híbrido e uma rede neural em grafos treinada pelos autores. O objetivo secundário é identificar qual o solver mais adequado para ser utilizado em uma aplicação real, equilibrando tanto tempo de execução quanto qualidade das respostas.

Materiais e Métodos

Foi gerado um script em Python para criar matrizes simétricas aleatórias com diferentes tamanhos usadas como matrizes de distância para simular diferentes instâncias do PCV, que foram então utilizados para testar e comparar cinco algoritmos de famílias distintas: o solver Lin-Kernighan-Helsgaun (LKH3), de Helsgaun (2017); a Iterated Local Search (ILS), de Lourenço et al. (2003); a Adaptive Large Neighborhood Search (ALNS), de Ropke and Pisinger (2006); a Hybrid Genetic Search (HGS), de Vidal (2022); e uma Graph Neural Network (GNN) treinada para prever o arrependimento associado à troca de diferentes arestas, seguindo Kool et al. (2019).

O experimento abrange cinco tamanhos de instância: 5, 10, 20, 50 e 100 paradas com 20 testes cada, implementados em Python 3.11 e executados na mesma máquina. Três métricas foram registradas por execução: o gap de otimalidade, isto é, o quanto o custo da rota

excede percentualmente o melhor custo obtido para aquela instância por qualquer solver; o tempo de execução, em segundos; e, para o experimento como um todo, a taxa de vitória, sendo essa a porcentagem de execuções que alcançaram esse melhor custo.

Resultados

Até 20 paradas, os solvers são praticamente indistinguíveis em qualidade, com a única exceção do ALNS, que já perde 0,887% para 10 paradas e 1,996% em 20 como visto na Figura 1. As diferenças só aparecem conforme as instâncias crescem: em 100 paradas, o ALNS chega a um gap médio de 4,251%, a GNN a 1,336% e o ILS a 0,258%, enquanto HGS e LKH3 permanecem em 0,000%.

O tempo de execução, portanto, os separa de forma muito mais nítida, como é evidenciado na Figura 2, onde o LKH3 praticamente não escala, indo de 0,061 s em 5 paradas para 0,135 s em 100, enquanto o ALNS sobe para 27,945 s na maior instância, com a GNN em 12,030 s, ILS em 8,124 s e o HGS em 7,432 s.




Figura 1: Gap médio de otimalidade por tamanho de instância. Fonte: Produzido pelos autores.




Figura 2: Tempo médio de execução em escala logarítmica. Fonte: Produzido pelos autores.

Considerando os dois eixos com dados de TSP100, a Figura 3 mostra que o LKH3 é o solver que melhor combina um bom gap médio de otimalidade de rota a um tempo mais de 50 vezes menor que o do HGS, seu concorrente direto em qualidade. A taxa de vitória apresentada na Figura 4 evidencia que o empate em qualidade entre os dois não é precisamente exato, já que o HGS devolveu a melhor rota em 100% das execuções, contra 99% do LKH3, mas a diferença permanece inferior a 0,005% do gap médio. Nota-se ainda que o ILS alcançou a melhor rota em 89% das execuções, a GNN em 79% e o ALNS em apenas 49%.




Figura 3: Qualidade versus tempo nas instâncias de 100 cidades; o LKH3 é o único solver não dominado. Fonte: Produzido pelos autores.




Figura 4: Porcentagem de execuções em que cada solver alcançou a melhor rota conhecida. Fonte: Produzido pelos autores.

Conclusões

Para o conjunto de instâncias avaliado, o LKH3 se mostra o melhor solver no geral: é estatisticamente tão preciso quanto a melhor alternativa e executa em uma fração de segundo, o melhor comportamento compatível com uma aplicação. O HGS permanece como referência em qualidade de solução e seria a alternativa natural sempre que o tempo de execução for irrelevante. O ALNS foi o solver mais fraco nos dois eixos, e a GNN se mostra bastante promissora, principalmente para instâncias maiores e assimétricas, mas ainda não competitiva nessas escalas. Os autores declaram não haver conflito de interesses.

Todos os autores aprovaram a versão final do resumo.

Esta pesquisa foi realizada com o apoio da Fundação de Amparo à Pesquisa do Estado de São Paulo (FAPESP).

Referências

- Keld Helsgaun. An extension of the Lin–Kernighan–Helsgaun TSP solver for constrained traveling salesman and vehicle routing problems. Technical report, Roskilde University, Roskilde, Denmark, 2017.
- Wouter Kool, Herke van Hoof, and Max Welling. Attention, learn to solve routing problems! In *International Conference on Learning Representations (ICLR)*, 2019.
- Helena R. Lourenço, Olivier C. Martin, and Thomas Stützle. Iterated local search. In *Handbook of Metaheuristics*, pages 320–353. Springer, Boston, MA, 2003.
- Stefan Ropke and David Pisinger. An adaptive large neighborhood search heuristic for the pickup and delivery problem with time windows. *Transportation Science*, 40(4):455–472, 2006.
- Thibaut Vidal. Hybrid genetic search for the CVRP: Open-source implementation and SWAP* neighborhood. *Computers & Operations Research*, 140: 105643, 2022.